

Estrategia de Pairs Trading con Filtro de Kalman

Nicolás Ramírez Castro

Maximiliano Hernández Aparicio

1. Introducción

Este reporte busca dar a entender el desarrollo e implementación de una estrategia de Pairs Trading aplicada a los activos **DAL** (Delta Air Lines) y **UAL** (United Airlines). Esta estrategia es utilizada en el ámbito de la gestión de portafolios y trading cuantitativo, y se basa en identificar dos activos cuyo comportamiento histórico muestra un alto grado de comovimiento o cointegración.

La hipótesis fundamental detrás de Pairs Trading es que, ante desviaciones de la relación histórica entre los dos activos, existe una oportunidad de arbitraje: cuando el spread se aleja de su media histórica, el trader puede abrir una posición de compra (long) en el activo infravalorado y una posición de venta (short) en el activo sobrevalorado, con la expectativa de que el spread regresará a su media.

En este proyecto, además de utilizar las pruebas tradicionales de cointegración (Engle-Granger y Johansen), se implementó un Filtro de Kalman para estimar el hedge ratio dinámico y ajustar la estrategia de cobertura en tiempo real. Finalmente, se diseñó un backtesting para evaluar el desempeño histórico de la estrategia, calculando métricas clave como el Sharpe Ratio, el Sortino Ratio y el Max Drawdown.

2. Desglose de los Pasos

2.1. Descarga y Normalización de Datos (Descarga_Activos.py)

- Se descargaron los datos históricos de precios de cierre ajustados para **DAL** y **UAL** desde Yahoo Finance.
- Se aplicó una normalización para facilitar la comparación visual de los activos.




Figura 2.1 Grafico de precios de activos.

2.2 Pruebas de Estacionaridad (Prueba_DickeyFuller.py)

- Se realizó la Prueba de Dickey-Fuller Aumentada (ADF) a cada serie individual, con el objetivo de verificar si son series no estacionarias, una condición clave para evaluar cointegración.

```
Prueba ADF para DAL:
- Estadístico ADF: -2.3903
- p-valor: 0.1445
- Umbrales críticos: {'1%': np.float64(-3.4329507078222634), '5%': np.float64(-2.8626889823128554), '10%': np.float64(-2.567381647203466)}

P-value es mayor a 0.05, por lo que la serie DAL NO es estacionaria.

Prueba ADF para UAL:
- Estadístico ADF: -1.3776
- p-valor: 0.5929
- Umbrales críticos: {'1%': np.float64(-3.4329424595562963), '5%': np.float64(-2.862685339846278), '10%': np.float64(-2.5673797079109892)}

P-value es mayor a 0.05, por lo que la serie UAL NO es estacionaria.

Ambas series no son estacionarias. Son aptas para una estrategia de pairs trading.
```

Figura 2.2 Resultados de pruebas ADF para cada activo.

2.3 Pruebas de Cointegración (Prueba_EngleGranger, Prueba_Johanssen.py)

- **Engle-Granger:** Se realizó una regresión OLS entre ambos activos y se evaluaron los residuos mediante ADF para verificar si son estacionarios.
- **Johansen:** Se utilizó el método multivariado de Johansen para identificar vectores de cointegración y obtener un **modelo de spread**.

OLS Regression Results						
=====						
Dep. Variable:	DAL	R-squared:	0.773			
Model:	OLS	Adj. R-squared:	0.773			
Method:	Least Squares	F-statistic:	8586.			
Date:	Fri, 28 Feb 2025	Prob (F-statistic):	0.00			
Time:	19:42:50	Log-Likelihood:	-7089.1			
No. Observations:	2527	AIC:	1.418e+04			
Df Residuals:	2525	BIC:	1.419e+04			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	18.5917	0.273	68.084	0.000	18.056	19.127
UAL	0.4146	0.004	92.661	0.000	0.406	0.423
=====						
Omnibus:	47.830	Durbin-Watson:	0.018			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	36.413			
Skew:	0.203	Prob(JB):	1.24e-08			
Kurtosis:	2.575	Cond. No.	209.			
=====						

Figura 2.3 Resultados de la regresión OLS

En base a los resultados obtenidos, si es posible continuar con la prueba Johansen. Se observó que el valor de **Rcuadrado** si es mayor a 0.7, que la prueba **Omnibus** es igual a 0, la prueba **JB** es menor que 0, por lo que si cumple con los requerimientos para proseguir como Trade de pares.

```

El Hedge Ratio es 0.4146 UAL por 1 de DAL

Prueba de Estacionariedad (ADF) sobre los residuos:
- ADF Statistic: -3.5961
- P-value: 0.0058
- Critical vals: {'1%': np.float64(-3.4329424595562963), '5%': np.float64(-2.862685339846278), '10%': np.float64(-2.5673797079109892)}

P-value es menor a 0.05 por lo que los residuos son estacionarios y se CONFIRMA la relación de cointegración.

```

Figura 2.3 Resultado de prueba ADF sobre residuales de la regresión OLS

En este caso en base a los resultados de la prueba ADF sobre los residuales de la regresión OLS, se confirma la cointegración de estos dos activos por lo que la continuidad del modelo puede seguir. De igual manera obtuvimos el Hedge Ratio con los resultados de la regresión OLS, sin embargo, este no será el que usemos, mas adelante usaremos el Filtro de Kalman para obtener nuestro Hedge Ratio. Despues de obtener estos resultados pasamos a la prueba de Johansen.

```
Eigenvalue Statistics: [15.23371309  1.72844104]
Trace Statistics: [13.50527204  1.72844104]
Eigenvalues: [0.00533434  0.0006843 ]
Eigenvectors:
[[ 0.24782256 -0.03662185]
 [-0.09437834  0.07092133]]

Nuestro modelo de spread es:
u_t = 0.24782 * UAL -0.09438 * DAL
```

Figura 2.3 Resultado de Prueba Johansen

Una vez teniendo los resultados de la prueba Johansen, podemos armar nuestro modelo de spread usando los Eigenvectores, y se hace la ecuación que se muestra como u_t .



Figura 2.3 Modelo de spread normalizado

Este sería el spread modelo normalizado que se generó usando el hedge ratio de la regresión OLS.

2.4 Estimación Dinámica del Hedge Ratio

- Se implementó un **Filtro de Kalman**, lo que permitió estimar un **hedge ratio dinámico**, adaptándose a posibles cambios en la relación entre los activos a lo largo del tiempo.
- Se graficó la evolución temporal del hedge ratio estimado.





Figura 2.4 Hedge Ratio Dinámico con Filtro de Kalman

En este paso, se usó el filtro de Kalman para calcular y poder ajustar la cobertura en tiempo real dándonos una ventaja sobre los métodos de regresión OLS que suponen una relación fija entre los activos.

**** DUDAS y como se continuo el proyecto en base a estos problemas ****

Después de este paso, teníamos entendido que no debíamos usar el hedge ratio que se obtuvo en base a la regresión OLS y teníamos que usar el hedge ratio obtenido por el Filtro de Kalman, sin embargo, nos surgieron dudas y problemas que no supimos como resolver a la perfección. En este caso al querer obtener un spread model no supimos cómo hacerlo bien pues el hedge ratio iba cambiando conforme los precios de los activos se movían, al intentar crear un spread model para estos nuevos hedge ratios nos salía lo siguiente:



La verdad no nos hizo mucho sentido este nuevo spread model, pero aun así continuamos con los siguientes pasos hasta llegar al backtesting y obtuvimos el siguiente resultado el cual tampoco nos hizo mucho sentido:



El resultado del backtesting fue realmente una copia del spread normalizado, por lo que la verdad decidimos utilizar el hedge ratio de la regresión OLS para poder tener una conclusión y un proyecto con sentido, pero quisimos mostrar los problemas que tuvimos para que entendiera por qué no utilizamos un spread model basado en el hedge ratio de Kalman, de igual manera seguimos teniendo la duda de cómo hacer un spread model usando hedge ratio dinámicos por lo que quisiéramos saber cómo hacer bien esta parte del proyecto.

****Continuación del desglose de pasos****

2.5 Generación de Señales de Trading

- Con el **spread normalizado** obtenido, se definieron **reglas de trading** basadas en umbrales de **1.5 desviaciones estándar**.
- **Reglas de trading:**
 - Cuando el spread **supera +1.5 sigma**: **Vender (short)** el activo sobrevalorado y **comprar (long)** el infravalorado.
 - Cuando el spread **cae por debajo de -1.5 sigma**: **Comprar (long)** el activo sobrevalorado y **vender (short)** el infravalorado.
- Se generaron **gráficos** que muestran las señales de compra/venta sobre los **precios de los activos** y sobre el **spread**.




Figura 2.5 Señales de Trading en los activos

2.6 Backtesting de la Estrategia

- Se simuló la evolución de un portafolio inicial de **\$1,000,000**.
- Se incorporaron **costos de transacción de 0.125%** por cada operación.
- Se calculó la evolución histórica del capital (**equity curve**).
- Se calcularon **métricas clave de desempeño**:
 - **Sharpe Ratio**: Relación entre retorno esperado y volatilidad total.
 - **Sortino Ratio**: Relación entre retorno esperado y volatilidad negativa (**drawdowns**).
 - **Máximo Drawdown**: Pérdida máxima desde un pico de capital.

```
Sharpe Ratio: 0.4295
Sortino Ratio: 0.4244
Max Drawdown: -46.9417%
```

Figura 2.6 Resultados de las métricas

Sharpe Ratio: Bajo, refleja que el retorno no compensa bien el riesgo

Sortino Ratio: Similar al Sharpe, indica alta volatilidad negativa (muchas caídas)

Max Drawdown: Muy alto, expone un alto riesgo de pérdidas profundas

El conjunto de métricas muestra que **la estrategia tiene potencial para generar retornos**, pero está expuesta a un **nivel de riesgo muy alto**. En particular, la magnitud del **Max Drawdown** es preocupante, lo que indica que en periodos de alta volatilidad o cambios estructurales, la estrategia podría generar pérdidas significativas.

2.7 Resultados y Análisis

- Se presentaron **gráficos y resultados** que muestran el desempeño de la estrategia.
- Se identificaron **periodos de ganancia y periodos de pérdidas significativas**, particularmente asociados a cambios estructurales en el comportamiento de los activos, como la crisis por la pandemia en 2020.



Figura 2.7 Gráfica del backtesting

Período de Pérdidas Significativas (Drawdown)

- Observamos que el capital cae abruptamente en 2020, coincidiendo con la crisis global del COVID-19.
 - Durante esta época, los mercados financieros experimentaron un periodo de **alta volatilidad e inestabilidad estructural**.
 - Las relaciones históricas entre activos (como DAL y UAL) pueden haber **roto su cointegración temporalmente** debido a las condiciones extremas (suspensión de vuelos, restricciones globales).
 - El modelo de trading de pares asume que el spread tiende a regresar a la media (reversión a la media), pero en crisis de alta magnitud como la pandemia, ese comportamiento puede dejar de cumplirse. En estos casos, el **spread se desvía persistentemente** y la estrategia acumula pérdidas al mantener posiciones perdedoras por más tiempo.

Recuperación Posterior

- Tras el impacto inicial de 2020, el portafolio muestra **una recuperación importante**, alcanzando nuevos máximos hacia finales de 2024 y 2025.
 - Una vez que el mercado comenzó a normalizarse y los vuelos se reanudaron, la relación entre DAL y UAL volvió a una dinámica más predecible.
 - La estrategia volvió a capturar oportunidades de arbitraje entre los dos activos, permitiendo la recuperación.

Comportamiento en 2023-2024

- El capital muestra un comportamiento más volátil, con varias subidas y bajadas.
- Esto refleja que **la relación entre los activos puede estar cambiando nuevamente** o que los umbrales de entrada y salida (± 1.5 sigma) son demasiado ajustados para la nueva realidad de mercado.
- Podría ser necesario **recalibrar el umbral o incorporar algún mecanismo de protección ante eventos de alta volatilidad**.

3. Conclusiones

Los resultados obtenidos muestran que la estrategia es capaz de generar rendimientos en periodos de estabilidad relativa, cuando la relación entre los activos se mantiene estable y la reversión a la media es observable. Sin embargo, en entornos de alta volatilidad, como el periodo de la pandemia en 2020, la estrategia sufre pérdidas significativas. Esto ocurre porque los supuestos fundamentales de la estrategia (cointegración y reversión a la media) dejan de cumplirse cuando los activos sufren shocks estructurales o cambian permanentemente su relación histórica.

Un hallazgo relevante fue la dificultad de construir un **modelo de spread confiable usando un hedge ratio dinámico**. Aunque el filtro de Kalman proporciona una estimación más flexible que la regresión OLS, la interpretación y operacionalización de un spread dinámico presenta retos adicionales, particularmente al definir umbrales consistentes de entrada y salida. Esta dificultad es común en la práctica, ya que los modelos dinámicos suelen ser más sensibles al ruido de mercado.

A pesar de las limitaciones observadas, el análisis permitió obtener un entendimiento profundo sobre la importancia de validar constantemente la

estabilidad de la relación entre activos, recalibrar parámetros y adaptar las reglas de trading a diferentes entornos de mercado. En resumen, el proyecto mostró que **el Pairs Trading es una estrategia con potencial**, pero que su éxito depende críticamente de:

- La correcta selección de pares.
- La robustez de las pruebas de cointegración.
- La correcta implementación de un spread dinámico.
- Un monitoreo constante de la estabilidad de la relación.